

# 多视图 blog学习笔记

---

## 1. 多视图学习的概念

---

概念：多视图学习是将两个或两个以上的视图数据加以融合的机器学习策略。在实际生活中，很多数据都可以从多个“视角”进行描述，例如同一个物体从不同角度拍摄的图片，同一个语义的不同语言的表达，或者是同一个网页上包含的文字和链接等。这些来自不同视角的表示数据都可以当作是不同的视图。除了同时利用多个视图特征带来的信息量的增加以外，多视图学习在本质上更注重挖掘数据之间的差异性和互补性，在已有数据的基础上，从算法层面优化学习的效果。

例子：现在构建一个公司防御系统，来检测公司员工的异常行为。这个防御系统可以看到员工的邮件往来网络，以及员工访问公司文件的日志。系统通过文件访问日志了解到，员工A,B,C只访问资源I，员工D,E,F,G则同时访问资源I和资源II。这时没有异常信息可以被检测到。接下来，系统通过邮件网络了解到：员工{A,B,C,D}处于一个团队，员工{E, F, G}则在另外一个团队。通过这2个视图，我们则可以检测到员工D的异常行为。因为第一个团队的{A,B,C,D}里只有他一人同时访问资源I和资源II，在这里我们可以把这个团队理解为项目I的开发部门。{E,F,G}则同时负责项目I和项目II（比如说管理角色）。对第二个团队来说，同时访问资源I和资源II是很正常的，而第一个团队的D则不应该访问资源II。我们可以看到有必要从两个不同的视图来判断员工D有异常行为。

由此，我们可以通过多视图学习中得来的差异性与互补性找到数据中更深层的潜在语义。

## 2. 多视图学习的主流分类方法

---

### 2.1 典型相关性分析(CCA)

最大化两个视图之间的相关系数，寻找各个视图到共同空间的映射向量（典型向量），一般通过线性变换寻找典型向量，在这个共同空间中，各个视图具有最大相关性。特别的，在分类任务中可以将输出（label）看作一个视图，然后寻找输入数据（多个视图）和输出视图之间的相关性，直接完成分类任务。一般完美的相关性将会导致模型的过拟合，最新的研究有通过规范化来寻找泛化性更强的模式[相关论文](#)。

下图为基于CCA的多视图学习基本模式：

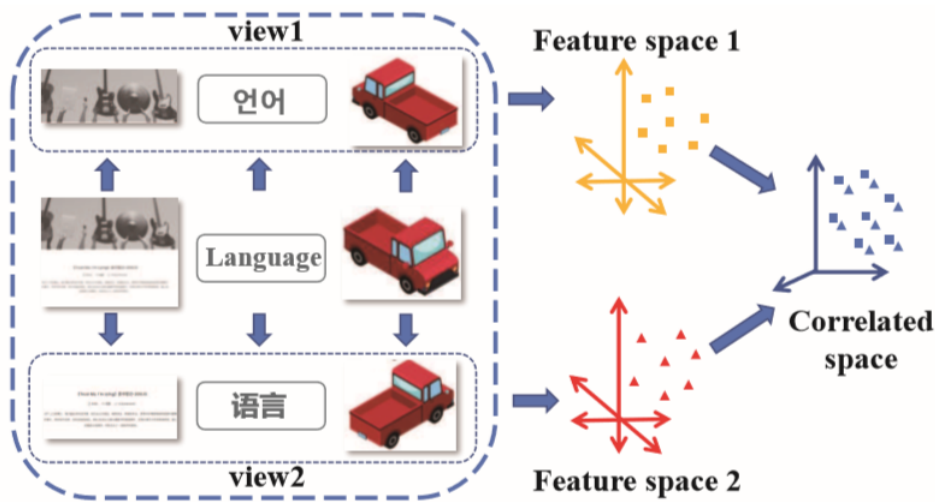


Fig. 1. Multi-view data and CCA-based subspace learning.

### 2.1.1 广义典型相关性分析

传统的CCA算法无法计算三个或者三个以上的视图的相关性，广义的CCA解决了这个问题；

类别	经典方法	年份	主要思路
间接法	SUMCOR-GCCA	1961	直接最大成对视图相关系数的和。
	MAXVAR-GCCA	1968	将多个视图映射到一个共同的子空间，在这个共同的子空间中所有视图的相关性最大
	LS-CCA	2007	基于最小二乘回归的方法，主要思路是最小化映射之后不同视图之间的距离。经过证明，该方法本质上完全等同于 MAXVAR-GCCA。
直接法	TCCA	2015	通过对多个视图的高维协方差矩阵进行分析，直接最大化所有视图的相关性。

### 2.1.2 非线性CCA

针对传统CCA不能计算数据之间的非线性相关性的问题，有三种主要的解决思路：

i 核映射：首先利用核函数将数据映射到高维的空间中，然后应用线性CCA对相关性进行计算。最具有代表性的方法是核典型相关性分析（Kernel Canonical Correlation Analysis, KCCA）

和核函数与核技巧的关键就是将非线性数据映射到更高维的线性可分的空间，使其更容易完成其他任务；

ii 局部保留：基于局部保留的思路来源于图模型，旨在实现全局非线性降维的同时保留数据局部的线性结构，可以理解为对局部的线性结构采用CCA进行特征学习

iii 神经网络：基于神经网络的方法可以处理非常复杂的数据之间的非线性关系。做法是首先利用神经网络对数据进行非线性映射，然后利用线性CCA计算数据映射之后的相关性；这种方法的本质采用神经网络的非线性映射能力对数据进行了初步的特征提取，进而采用CCA进行相关性分析；

### 2.1.3 基于CCA多视图的应用

**i 多视图模式识别：**直接拼接多视图特征、主要视图和辅助视图（进行预测时使用主视图的分类器）、将标签作为一个视图

**ii 跨模态检索与分类：**“模态”也可以理解为“视图”，例如图片和文本是两个不同模态（视图），将不同视图的数据通过CCA映射到一个共同空间中训练分类器

注：不理解，也没有找到相关文献

**iii 自然语言处理：**为不同的语言创造不同视图，从而从不同语言的词向量中学习具有更高相似度的特征表示

**iiii 脑机接口** 直接计算所采集的脑电信号与人工构造的特定频率的模板信号之间的相关性，根据相关性的的大小给出频率识别的结果。

## 2.2 协同训练

比较单一，且在笔记[multi-view-Sun Shiling]已经介绍过

## 2.3 多核学习方法

经过多个核函数映射后的高维空间是由多个特征空间组合而成的组合空间，而显然组合空间可以组合各个子空间不同的特征映射能力，能够将异构数据中的不同特征分量分别通过最合适的单个核函数进行映射，最终使得数据在新的组合空间中能够得到更加准确、合理的表达，进而提高样本数据的分类正确率或预测精度。

### 2.3.1 合成核

把具有不同特性的多个核函数进行组合，就会得到包含各个单核函数的总体特性的多核函数。多核函数形成的方式本身就使得多核函数具有更加准确、更加强大的映射能力或者分类能力，特别是对于实际应用中样本数据具有比较复杂分布结构的分类、回归等学习问题，多核学习的优点非常明显。

一是多核的线性组合（直接求和、加权求和），二是保留原始核函数，通过矩阵进行核扩展，三是给核函数分配权值（通过对输入样本分配权值实现）

### 2.3.2 多尺度核

合成核方法都是根据简单核函数的线性组合,核函数参数的选择与组合没有依据可循,对样本的不平坦分布仍无法圆满解决,限制了决策函数的表示能力;

多尺度核方法的基础就是要找到一组具有多尺度表示能力的核函数., 例如高斯径向核[这里挖个坑，后面再填];

### 2.3.3 无限核扩展

无限核是从由多个基本核函数的合法集合所构成的一个凸壳中找到某个核,使其能最小化凸正则化函数.与其他方法相比,这个方法有一个独有的特征,即上述基本核的个数可以是无限多个,仅仅需要这些核是连续参数化的