

多视图—多视图机器学习综述（孙仕亮）

一、多视图学习概念

由不同的特征集或数据集的不同视图来完成学习任务；

例如：

在多媒体内容理解中，多媒体片段可以由其视频和音频信号同时描述。在网页分类中，网页可以由文档文本来描述，同时也可以由指向该页面超链接的锚文本来描述。另一个例子是，在基于内容的网络图像检索中，一个对象同时由图像的视觉特征和图像周围文本来描述。

二、早期多视图研究的代表

1. 标准相关分析（CCA）

CCA处理的问题不：拿到两组数据，第一组是人身高和体重的数据，第二组是对应的跑步能力和跳远能力的的数据。那么我们能不能说这两组数据是相关的呢？*

对于一维的数据，我们采用数理统计中的相关系数定义相关性，但是高维数据不适用；而CCA将多维的两组数据使用线性变换到一维度，然后再使用相关系数进行分析；

1.1 CCA算法思想

每一种降维方法都有原则和目标，例如pca的原则是投影方差最大，lda的投影原则是同类投影方差最小，异类投影方差最大；而CCA的降维标准是降维后的一维数据的相关系数最大；最后CCA算法由目标导向为一个凸优化过程，具体的求解方法和有两种：一是奇异值分解、二是特征分解；具体的求解过程见[cca算法求解](#)

1.2 CCA算法流程

1.3 CCA算法小结

1. 依赖于数据的线性表示
2. 可以通过次特征值、次奇异值进行扩展相关分析

2. 多视图协同学习

在多视图情况下，将有标注数据和无标注数据结合起来，训练一个强泛化能力的分类器

首先分别从两个视图中训练两个弱分类器。然后，两个分类器运用未标注的数据中高度可信的预测来扩大标注数据集，以供进一步训练。重复该过程直到满足终止条件。最后，这两个分类器单独或共同对新样本进行预测。

2.1 协同学习的算法流程

输入：标记数据集 L ，未标记数据集 U 。

1. 用 L_1 训练视图 X_1 上的分类器 f_1 ，用 L_2 训练视图 X_2 上的分类器 f_2 ；
2. 用 f_1 和 f_2 分别对未标记数据 U 进行分类；
3. 把 f_1 对 U 的分类结果中，前 k 个最置信的数据（正例 p 个反例 n 个）及其分类结果加入 L_2 ；把 f_2 对 U 的分类结果中，前 k 个最置信的数据及其分类结果加入 L_1 ；把这 $2(p+n)$ 个数据从 U 中移除；
4. 重复上述过程，直到 U 为空集。

输出：分类器 f_1 和 f_2 。

三、多视图学习方法分类

3.1 多视图降维度

作为无监督学习的一个重要分支，降维的目的是用低维表征来表达高维数据，以揭示重要的潜在信息。它可以用于压缩、可视化或重新组织数据，也可以用作其他机器学习任务的预处理步骤；

而CCA是多视图降维的经典方法；

3.2 多视图半监督学习

半监督学习是解决数据无标签的经典方法，协同训练是多视图半监督学习的关键技术；

3.3 多视图监督学习

多视图监督学习的研究相对少于多视图半监督学习。一个原因可能是多视图半监督学习常常被认为是比多视图监督学习更困难和更一般的问题。

3.4 多视图主动学习

首先使用带标注样本在每一个视图下训练一个分类器，然后使用不同的分类器（每个视图一个分类器）预测无标签样本，贴上标签后加入到带标注数据集，重复这个过程。

3.5 多视图集成学习

集成学习的目标是使用多个模型（例如分类器或回归器）来获得比单个模型更好的预测性能。将有效的集成学习框架引入到多视图学习中可以有效提高算法性能。

3.6 多视图迁移学习

迁移学习或多任务学习的最新进展表明，将在一个或多个源任务中学到的知识迁移到相关的目标任务往往有利于改善学习性能。

这部分没有做过多的说明，给出一篇相关文章：

Xu和Sun提出了一种包括EMV-Adaboost变体在内的多视图迁移学习算法,并进一步将其扩展,使它能够利用多源学习的优势。

3.7 多视图聚类

- 1.利用多个视图中的信息进行聚类
- 2.不同视图的聚类使用彼此的信息进行自举
- 3.通过目标函数来约束多视图聚类,使得不同视图的聚类结构保持一致

四、多视图前沿问题

4.1 多视图学习的泛化误差上界

目前已经证明的最严格上界是PAC-Bayes上界,用PAC贝叶斯分析理论证明是否可以获得多视图学习器更紧致和更有洞见的上界是一个值得研究得问题

4.2 改近利用多视图的方法

- i. 协同训练式算法 -> 主要是利用迭代过程优化分类器
- ii. 协同规范化式算法 -> 将不同视图的学习器之间的差异作为目标函数的一部分
- iii. 随机一致性规范化->引入随即一致性, 详见[论文](#)

4.3 有效的视图构建方法

从单视图数据生成多视图数据,例如随即分割等方法的发现